Macroeconometría Aplicada en R

Clase 3. Procesos estocásticos y dinámica univariada

Nerys Ramírez Mordán

Empírica - Centro de Aplicaciones Económicas

Universidad Autónoma de Santo Domingo (UASD)

11 February 2026

Tabla de contenido

1. Introducción
2. Serie temporal y proceso estocástico
3. Caracteristicas del proceso (distribuciones)
4. Distribuciones conjuntas y dependencia temporal
5. Modelar dependencia temporal
6. Referencias
7. Anexos
   - Comunicación de datos con ggplot
   - Ecuación en diferencias: AR(1)

Section 1

Introducción

Serie temporal

- Una serie temporal es una **secuencia ordenada de observaciones** sobre una variable, registradas en puntos sucesivos del tiempo (Box y Jenkins, 1976; Wei, 1989).
- Formalmente, una serie temporal puede representarse como:

$$y_t : t = 1, 2, 3, \ldots, T$$

donde cada observación y_t corresponde al valor de la variable registrado en el instante t (Brockwell y Davis, 2002).

- **El orden temporal es esencial**: las observaciones no son intercambiables sin perder información.

Series temporales

- Las **series de tiempo** muestran una amplia variedad de características y una apreciación de estas es esencial para comprender tanto sus propiedades como su evolución (Mills, 2019).

$$y_t : \quad t = 1, 2, 3, \cdots, T$$

- Dada la secuencia $\{y_t\}$, donde t representa el período de observación:
  - Las observaciones suelen registrarse en **intervalos de tiempo regulares**, por lo que el **orden temporal es relevante** (Mills, 2019) y resulta razonable considerar la posible presencia de **dependencia temporal** (autocovarianza).
  - Dos variables pueden ser **independientes** o no (covarianza).
  - La **frecuencia de la serie** viene determinada por la periodicidad de los datos (mensual, trimestral, anual, etc.).
  - Dado t, y_t puede ser **discreta** ó no.

Componentes de una serie temporal

- Una serie temporal puede conceptualizarse como la suma de distintos componentes que capturan patrones sistemáticos y no sistemáticos en los datos (Enders, 2015):

$$y_t = T_t + c_t + s_t + e_t$$

- T_t representa el **componente de tendencia**, asociado a movimientos persistentes de **largo plazo** (Ojo tendencia $\neq$ *pendiente* (ver Enders, 2015, cap. 4));
- c_t corresponde al **componente cíclico**, vinculado a la dependencia temporal de **corto** y mediano **plazo**;
- s_t denota el **componente estacional**, que recoge patrones periódicos recurrentes;
- e_t es el **componente irregular**, que idealmente se comporta como ruido blanco.

Ejemplo 1:

- A modo de ilustración, los componentes de una serie temporal podrían especificarse como:

$$\text{Tendencia:} \quad T_t = 1 + 0.1\, t$$

$$\text{Estacionalidad:} \quad S_t = 1.6 \sin\left(\frac{\pi t}{6}\right)$$

$$\text{irregular:} \quad I_t = 0.7\, I_{t-1} + \varepsilon_t$$

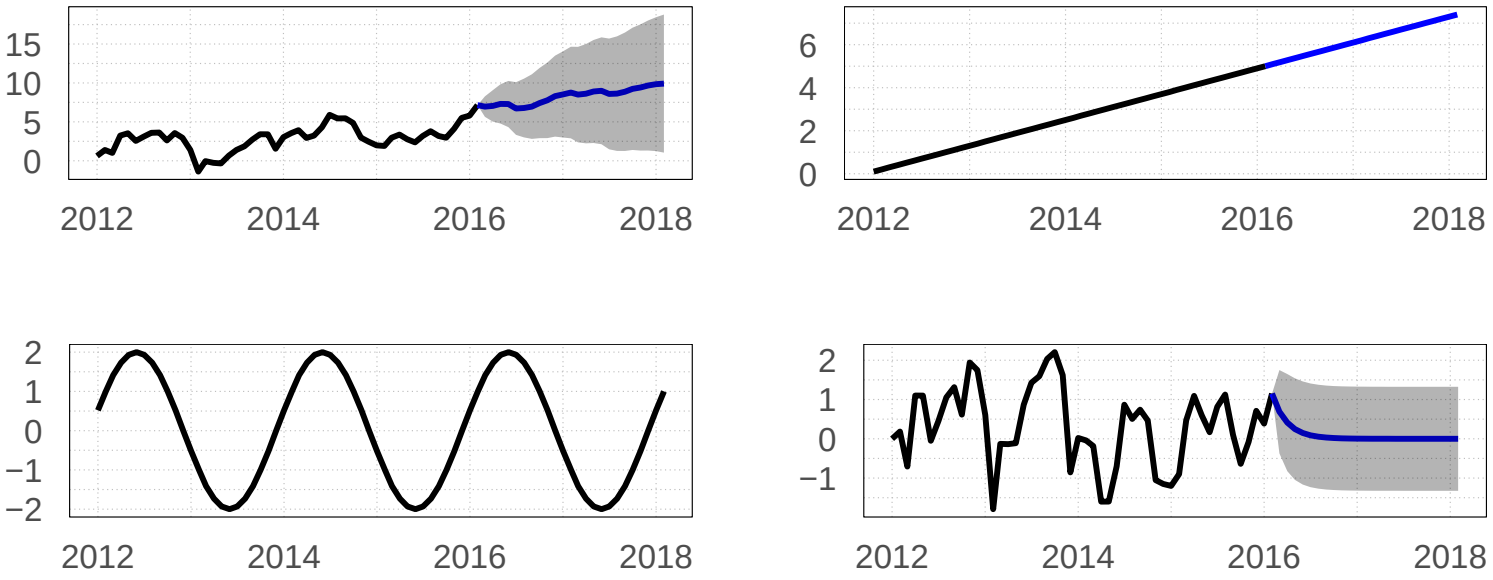

Figura 1: Descomposición y pronóstico de una serie temporal

Representar una serie temporal

- La representación de una serie temporal se realiza buscando: **tendencias**, componentes **estacionales**, **cambios bruscos** u observaciones no comunes (Brockwell y Davis, 2002).
- Estos elementos pueden no ser triviales observados mediante gráficos.

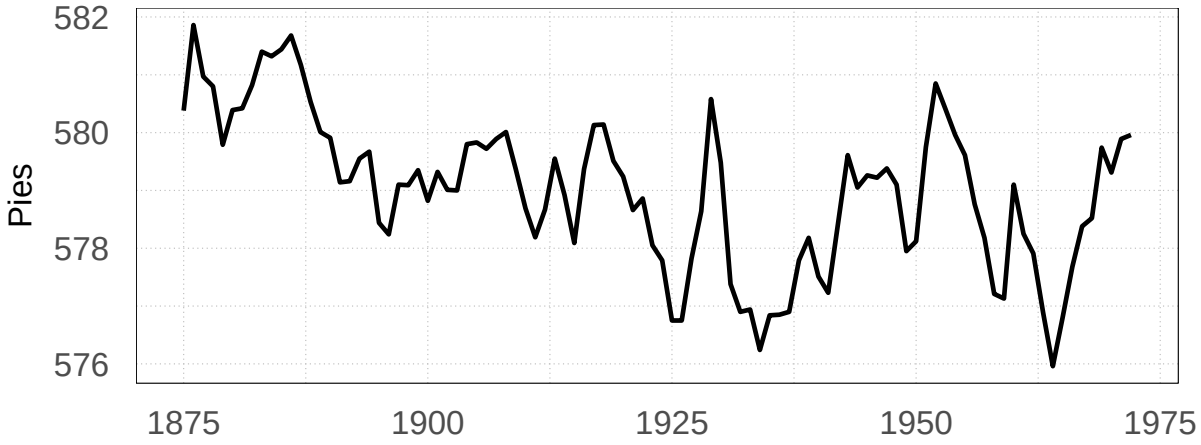

Figura 2: Nivel del lago Huron. Datos anuales 1875-1972

Ejemplo 2: Horas de sueño simuladas durante un año

- **Tendencia descendente** leve a lo largo del año ($T_t \downarrow$) por acumulación de fatiga.
- **Estacionalidad semanal** ($S_{w,t}$): más sueño los fines de semana.
- **Estacionalidad anual** ($S_{a,t}$): incremento en julio por vacaciones.
- **Perturbaciones aleatorias**: ruido.

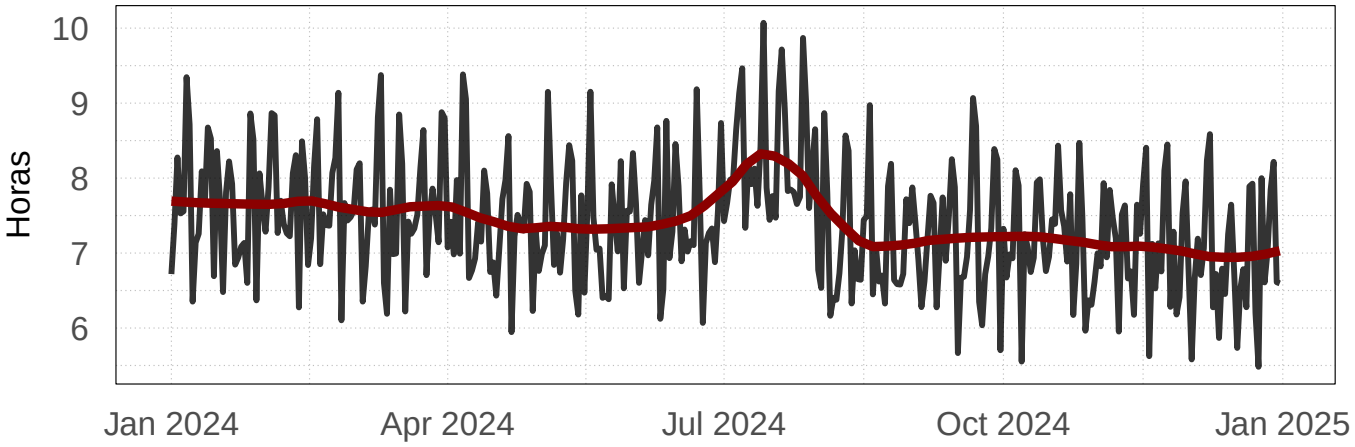

Figura 3: Horas de sueño simuladas. Datos diarios, 2025

Ejemplo 3: PIB trimestral

- **Tendencia creciente** a lo largo del tiempo ($T_t \uparrow$): refleja crecimiento estructural.
- **Estacionalidad trimestral** ($S_{q,t}$): mayor actividad en el cuarto trimestre.
- **Ciclos económicos** (C_t): oscilaciones suaves alrededor de la tendencia, por expansiones y recesiones.
- **Perturbaciones aleatorias**: ruido blanco.

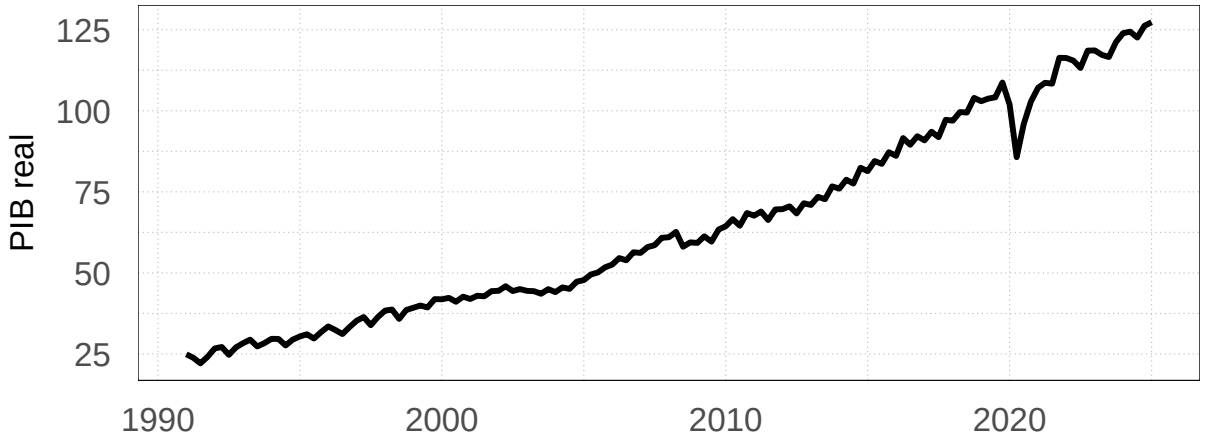

Figura 4: PIB real de la RD. Datos trimestrales 1991Q1 - 2025Q1

Ejemplo 4: Precio diario de una acción durante un año

- **Tendencia creciente** leve a lo largo del año ($T_t \uparrow$): refleja expectativas positivas del mercado.
- **Estacionalidad semanal** ($S_{w,t}$): menor rendimiento los lunes (`efecto lunes`).
- **Estacionalidad anual** ($S_{a,t}$): repunte en diciembre.
- **Perturbaciones aleatorias**: ruido.

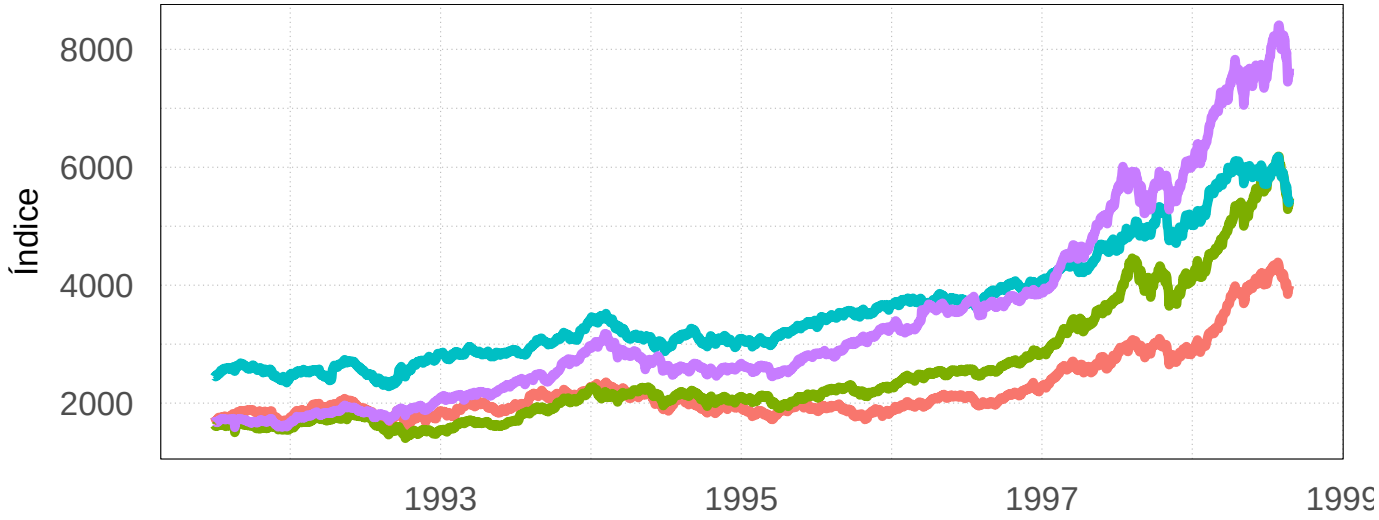

Figura 5: Índices bursátiles europeos (EuStockMarkets). Datos diarios 1991-1998

Modelos de series tempporales

- Una vez caracterizada la dinámica del proceso estocástico subyacente, los modelos de series temporales buscan **capturar la parte sistemática de la serie**, dejando el componente irregular como esencialmente impredecible (Enders, 2015, p. 3).
- La parte sistemática del proceso corresponde a aquella fracción de Y_t que puede ser explicada por su propia historia, mientras que el componente irregular representa innovaciones no anticipadas:

$$Y_t = \underbrace{\mathbb{E}(Y_t \mid \mathcal{F}_{t-1})}_{\text{parte sistemática}} + \underbrace{\varepsilon_t}_{\text{Irregular}} .$$

- **Análisis residual**: un modelo adecuado debe capturar la dependencia temporal presente en la serie, de modo que los residuos se comporten como **ruido blanco**.

Mapa conceptual de la clase 3

- El análisis de series temporales sigue una lógica inferencial precisa, que va del **proceso generador** a la **validación del modelo**:
  - Proceso estocástico ¿Qué es lo que realmente genera los datos que observamos?
  - Distribuciones. **Conocer mi serie** ¿Cuáles son las propiedades probabilísticas del proceso en cada instante del tiempo? Distribución marginal: $f(Y_t)$.
  - Dependencia temporal. **La información de hoy no es suficiente** ¿El valor de hoy contiene información sobre el valor de ayer? Distribuciones conjuntas y condicionales: $f(Y_t, Y_{t-1})$, $f(Y_t \mid Y_{t-1})$.
  - Autocorrelación. ¿Cómo **detectamos** empíricamente la dependencia temporal usando datos?
  - AR(1) ¿Cómo **modelamos** paramétricamente la dependencia temporal observada?

Section 2

Serie temporal y proceso estocástico

Serie temporal y proceso estocástico

- Una serie temporal es una **sucesión de variables aleatorias** indexadas en el tiempo, denotada como $\{Y_t\}_{t=1}^{T}$, donde $t \in \{1, 2, 3, \ldots, T\}$ representa el periodo en el que se observa el dato (Novales, 2016, p. 1).
- Para cada valor t en el conjunto C, se define una variable aleatoria Z_t, y los valores observados de estas variables en diferentes instantes conforman una **serie temporal** (Alonso, nd).
- Un **proceso estocástico** (PE) $\{Z_t\}_{t \in C}$ es una sucesión de variables aleatorias Y_t definidas en un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$, donde:
  - Y_t es una variable aleatoria para cada $t \in C$.
  - t es el índice temporal que puede tomar valores en un conjunto C, que puede ser discreto o continuo.

Serie temporal y proceso estocástico

- Una serie temporal es una secuencia de observaciones sobre una variable, medidas en puntos sucesivos en el tiempo (Box y Jenkins, 1976).
  - Proceso estocástico: $\{Y_t\}_{t \in \mathbb{Z}}$
  - Serie observada: $\{x_1, \ldots, x_T\}$
- Es decir, la serie observada $\{y_1, y_2, \ldots, y_T\}$ es una particular **realización** de un PE, también conocida como **trayectoria**, donde en cada instante t se asocia una variable aleatoria Y_t.

Ejemplo: el dado como proceso estocástico

- En cada período $t = 1, \ldots, T$ se lanza un dado.
- La variable aleatoria Y_t toma valores en $\{1, 2, 3, 4, 5, 6\}$.
- La secuencia observada

$$\{x_1, x_2, \ldots, x_T\}$$

constituye una **realización (trayectoria)** del proceso estocástico $\{Y_t\}$.

Ejemplo 5: Lanzar un dado

- Al lanzar un dado, la variable aleatoria x representa el número que aparece en el lanzamiento. Al repetir esta experiencia T veces, se obtiene una secuencia de valores:

$$[X_1, X_2, \cdots, X_T]$$

que constituye una realización en un espacio de dimensión T, lo que refleja una experiencia T dimensional (Abellón, nd).

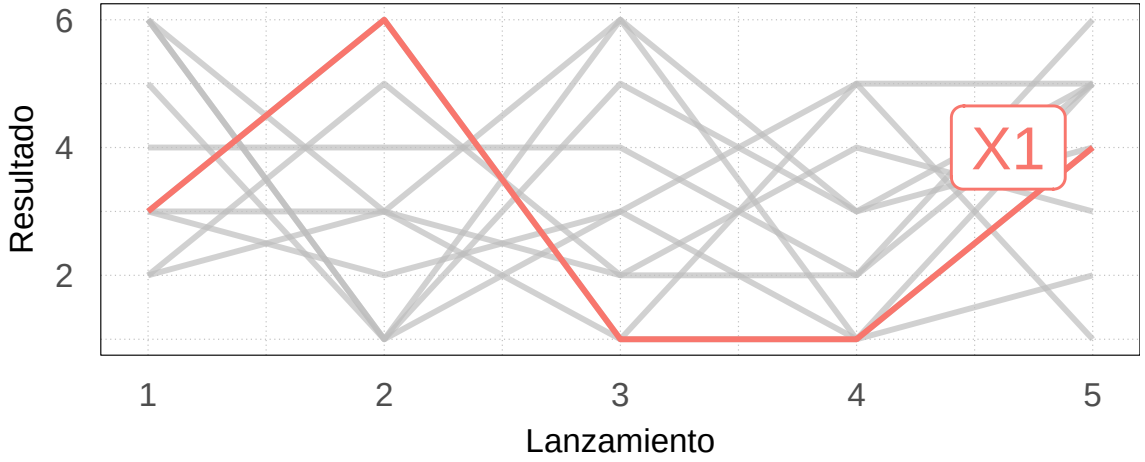

Figura 6: Simulando 10 lanzamientos de un dado durante 5 periodos

Section 3

Caracteristicas del proceso (distribuciones)

Caracteristicas de una serie temporal

- Como señala Novales (2016, p. 1), "**cada dato de una serie temporal debe interpretarse como una muestra de tamaño uno de la distribución de probabilidad correspondiente a la variable aleatoria en ese instante**".
- Como señala Mills (2015, p. 5), "en general, un proceso estocástico puede describirse mediante una **distribución de probabilidad** de dimensión T (aunque rara vez conocida en su totalidad), de modo que la relación entre una realización y el proceso estocástico es análoga a la existente entre la muestra y la población en estadística clásica".
- Según Mills (2015, p. 1), comprender el comportamiento de las series temporales es fundamental para lograr una interpretación empírica de los fenómenos económicos que trascienda los marcos puramente teóricos.
- El análisis de la **estructura estadística de las series temporales** —como su estacionalidad, tendencia, persistencia— es imprescindible al estudiar la **relación dinámica entre variables** (Lütkepohl y Krätzig, 2004, p. 8), así como para la elaboración de **pronósticos rigurosos** (Ramírez, 2017).

Funciones de distribución

- El análisis riguroso de una serie temporal requiere comprender las **propiedades probabilísticas del proceso estocástico subyacente**. Una caracterización adecuada de estas propiedades permite mejorar la capacidad predictiva, al modelar y extrapolar con mayor precisión los componentes deterministas y estocásticos de la serie (Enders, 2015, p. 1).
- En primer lugar, se analiza la **función de distribución univariada** asociada a cada variable aleatoria del proceso, denotada por $f_{Y_t}(y)$, para todo t.
  - Consideradas **en un solo período**, es decir, de manera marginal.
- Esta distribución describe la probabilidad de que Y_t tome determinados valores en un instante específico del tiempo, y permite caracterizar propiedades fundamentales del proceso, tales como:
  - la **media** $\mathbb{E}(Y_t)$,
  - la **varianza** $\mathbb{V}(Y_t)$,
  - y la **forma de la distribución** (asimetría, curtosis),

Ejemplo: distribución marginal y momentos (dado justo)

- Considere una variable aleatoria X asociada al resultado de un lanzamiento de un dado justo en un período dado.
- **Valores posibles:**

$$X \in \{1, 2, 3, 4, 5, 6\}$$

- **Distribución marginal:**

$$\mathbb{P}(X = k) = \frac{1}{6}, \quad k = 1, \ldots, 6$$

- A partir de la distribución marginal, es posible obtener características fundamentales del proceso, como su **media (valor esperado)**:

$$\mathbb{E}[X] = \sum_{k=1}^{6} k\, \mathbb{P}(X = k).$$

Ejemplo 6: Los momentos permiten estudiar caracteristicas de una serie, como el cálculo de probabilidades de una variable aleatoria $f(x)$ [recuerde $\mathbb{E}[x] = \int xf(x)dx$ ($f(x)$ equiv. $\mathbb{P}(Y = y)$)].

$$\Pr[x \geq 5] = \int_{5}^{+\infty} f(x)dx$$

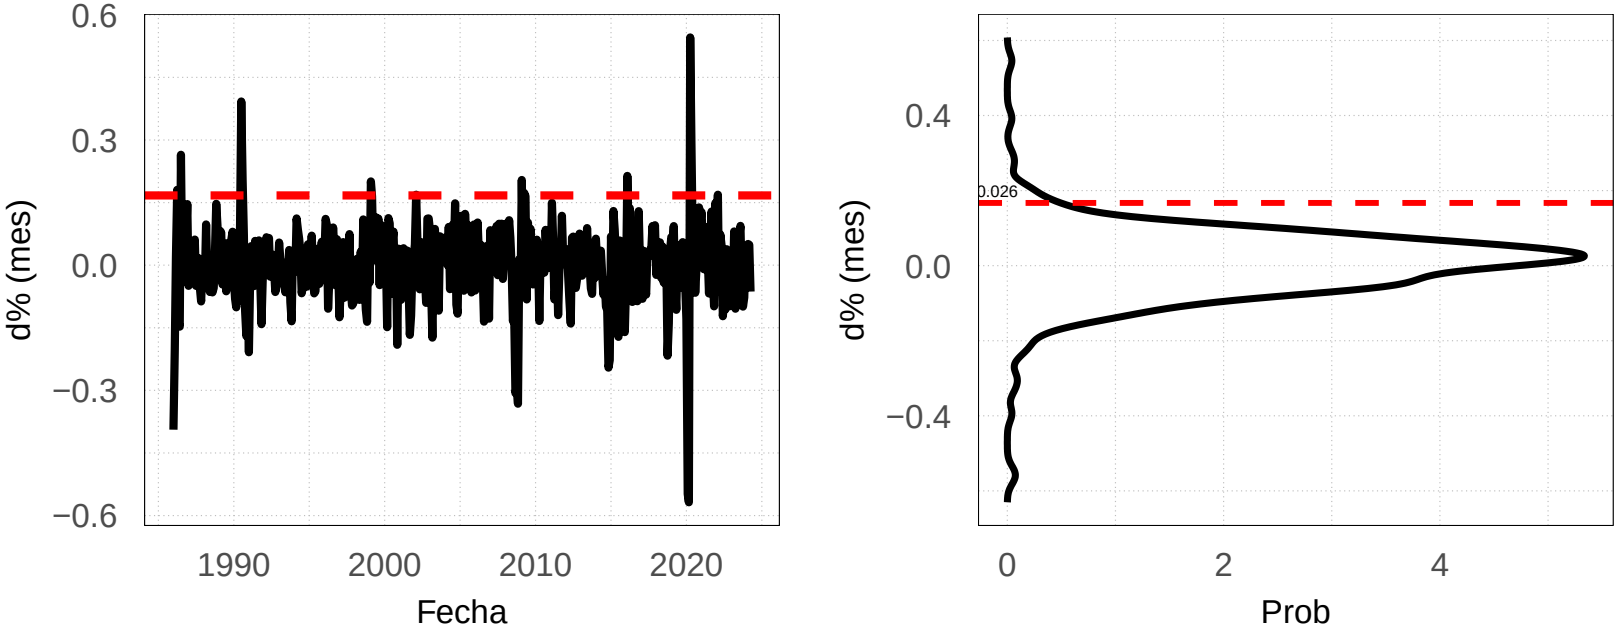

Figura 7: Variaciones mensuales del precio del petróleo, 1986-2024

Características del proceso

- Los **momentos** de una serie temporal son herramientas estadísticas que resumen propiedades fundamentales de la distribución de la serie, permitiendo caracterizar su comportamiento central, dispersión, asimetría y curtosis a lo largo del tiempo.
- Los momentos —centrados o no— se definen como:

$$\mu'_k = \mathbb{E}[Y_t^k] \quad \text{(momento no centrado de orden } k\text{)}$$

$$\mu_k = \mathbb{E}[(Y_t - \mu)^k] \quad \text{(momento centrado de orden } k\text{)}$$

Ejemplo 7: Intuición sobre la distribución

- Aunque dos series puedan compartir el mismo valor esperado, la **varianza** y los **centros de gravedad** de sus densidades pueden variar en función del tiempo o de condiciones específicas del entorno económico.
- Además, la **asimetría** de una distribución proporciona información sobre la dirección en la que es más probable que las observaciones se desvíen de su centro: una asimetría positiva sugiere colas más largas a la derecha, mientras que una negativa indica colas más largas a la izquierda.

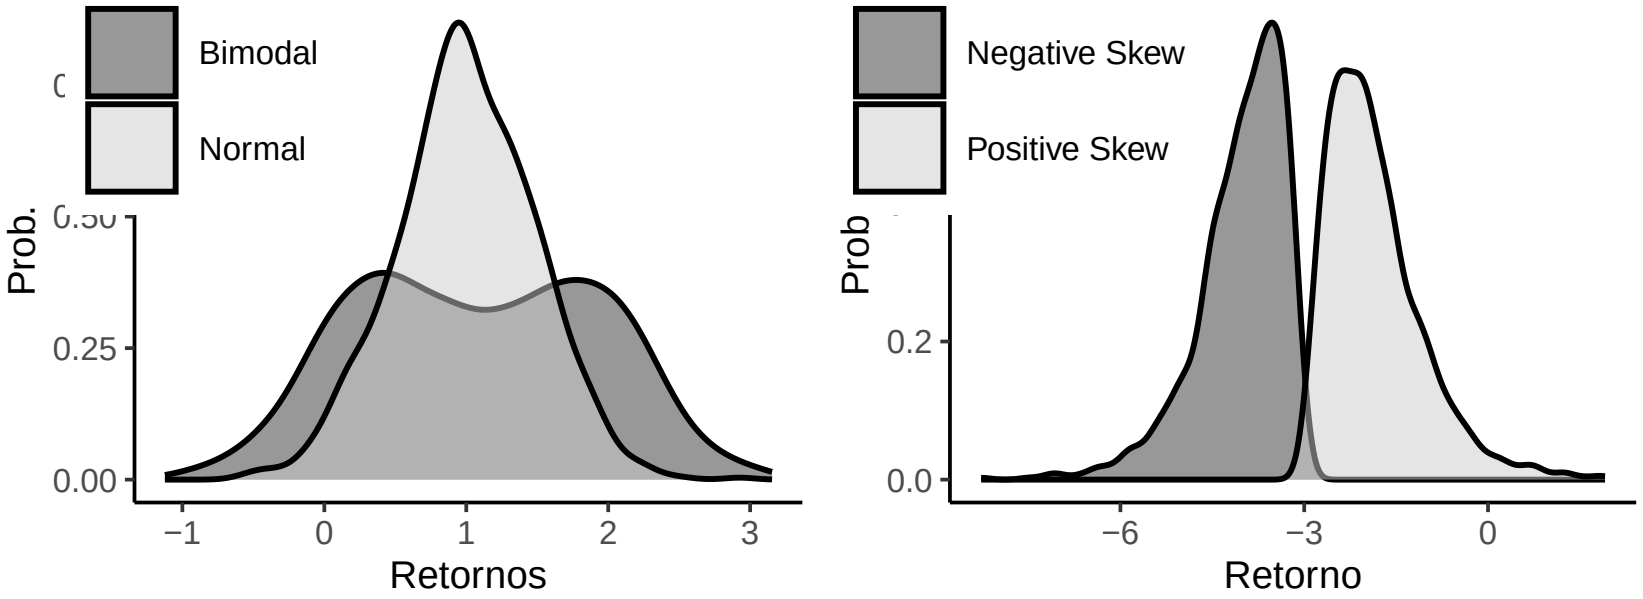

Figura 8: Distribuciones con distintas especificaciones

Ejemplo 7: Intuición sobre la distribución

- La **volatilidad** de una serie temporal no es necesariamente constante; puede variar a lo largo del tiempo, fenómeno conocido como **heterocedasticidad condicional**.
- Un aumento en la volatilidad implica una mayor probabilidad de ocurrencia de **eventos extremos** (colas gruesas), lo que eleva la incertidumbre y, en contextos financieros o macroeconómicos, se traduce en **mayores requerimientos de capital** o reservas para mitigar posibles pérdidas o impactos adversos.

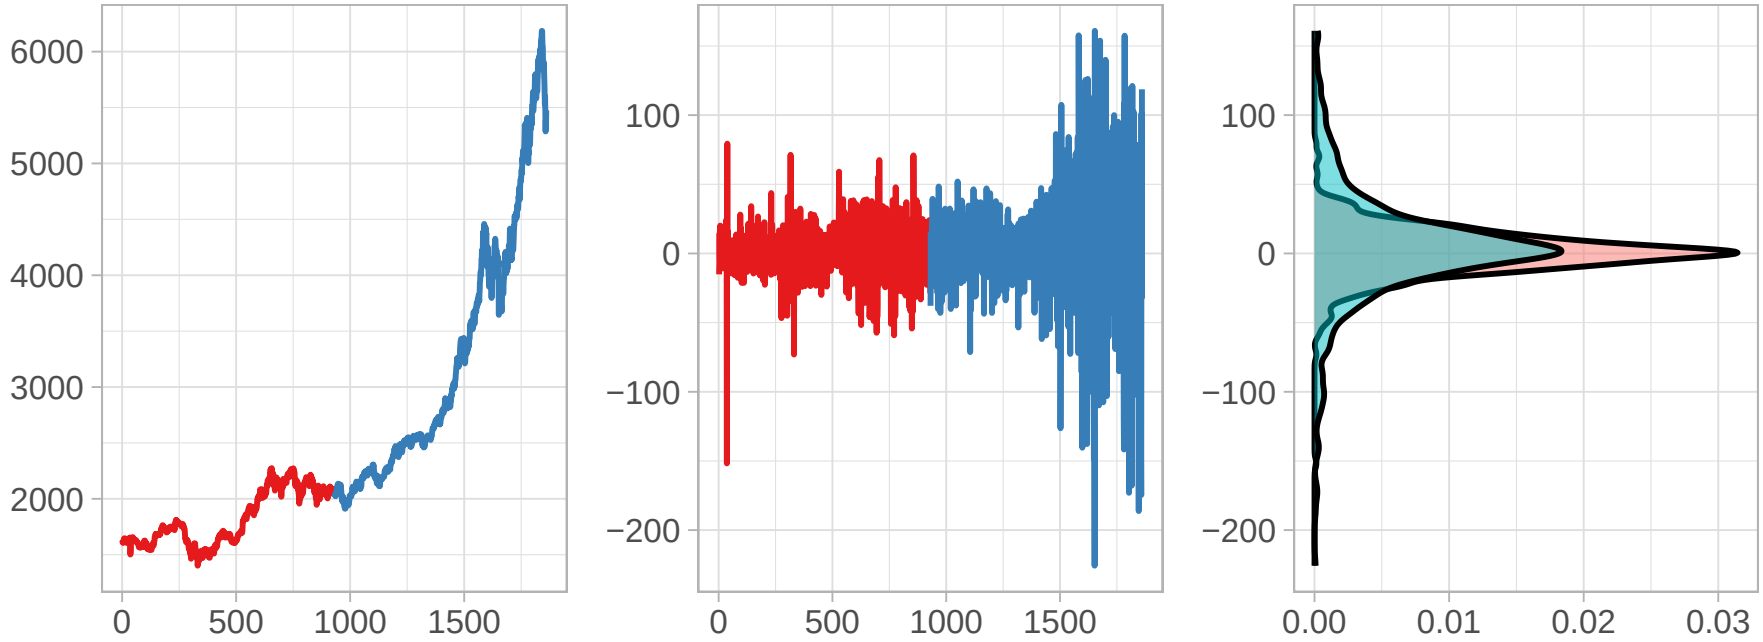

Figura 9: Análisis de volatildiad DAX

Ejemplo 8: Momentos de una serie en R

```r
xt <- c(2,4,7,8,9,6,3)
yt <- c(1:length(xt))

# Momentos
mean(xt) #E[x]
```

```
## [1] 5.571429
```

```r
mean(xt[yt>3]) #E[x|y>3]
```

```
## [1] 6.5
```

```r
var(xt)
```

```
## [1] 6.952381
```

```r
sd(xt)
```

```
## [1] 2.636737
```

Ejemplo 8: Momentos del precio del petróleo

```r
library(seasonal)
ajuste <- seas(serie_ts)
serie_ajustada <- final(ajuste)

# Cálculo de retornos mensuales en %
retornos <- diff(log(serie_ajustada), lag = 1) * 100
# Esperanza incondicional
mean(retornos, na.rm = TRUE)
```

```
## [1] 0.2719738
```

```r
# Esperanza condicional (condición: variación mensual > cierto valor)
umbral <- quantile(retornos, 0.75, na.rm = TRUE)  # Por ejemplo, el 25% superior
retorno_cond <- retornos[retornos > umbral]
mean(retorno_cond, na.rm = TRUE)
```

```
## [1] 10.8057
```

```r
# Momento parcial
estado <- ifelse(retornos > 0, "Sube", "baja")
tapply(retornos, estado, mean, na.rm = TRUE)
```

```
##      baja      Sube
## -7.606791  6.332562
```

Advertencias

- El interés principal recae en la **dinámica futura** de las series temporales, más que en su comportamiento histórico. Un ejemplo ilustrativo es la valoración de una opción tipo Call europea, cuyo precio depende de la distribución esperada del activo subyacente en el futuro:

$$C = e^{-rT}\mathbb{E}[\max(S_T - K, 0)]$$

$$\text{Payoff} = \begin{cases} S_T - K & \text{si } S_T > K, \\ 0 & \text{si } S_T \leq K. \end{cases}$$

- Los momentos de la distribución pueden **ser no estacionarios**, es decir, cambiar a lo largo del tiempo.
- **Los momentos de la distribución (media, varianza, etc.) solo son validos si la serie es estacionaria**.
- **Cambio de régimen** o estructura implica que el supuesto de constancia temporal (ergodicidad, ver anexo 3) se rompe.
- Momentos más allá del segundo (asimetría, curtosis) pueden ser extremadamente sensibles a **valores atípicos**.

Section 4

Distribuciones conjuntas y dependencia temporal

Corte transversal vs. serie temporal

- En un **corte transversal**: se observan múltiples unidades (individuos, hogares, ...) en un mismo momento en el tiempo.

$$\mathrm{Cov}(y_i, y_j) = 0 \quad \text{para } i \neq j$$

- En una **serie temporal** se observa una misma unidad (país, empresa, ...) a lo largo del tiempo.

$$\mathrm{Cov}(y_t, y_{t-k}) \neq 0 \quad \text{para algún } k$$

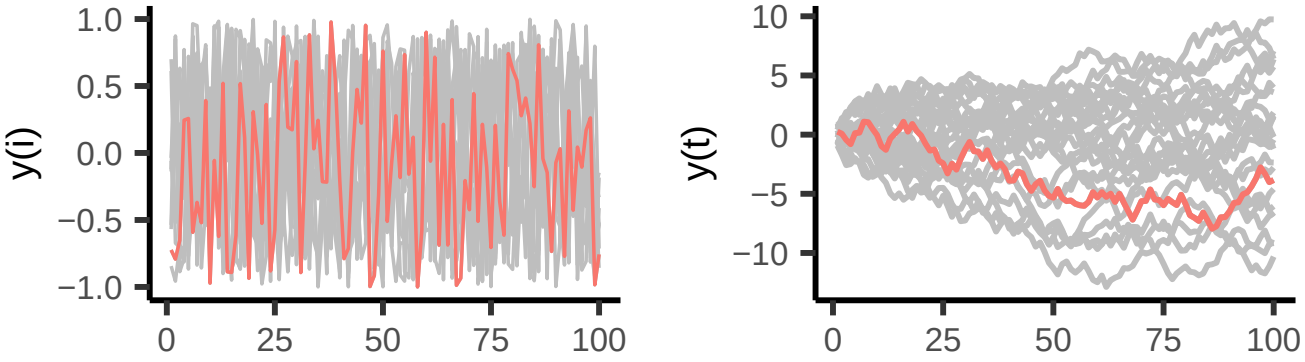

Figura 10: Series temporales vs. cortes transversales

Distribuciones conjuntas y dependencia temporal

- La caracterización de una serie temporal no se agota en el estudio de las distribuciones marginales. Para analizar la **dependencia temporal** es necesario examinar la relación probabilística entre observaciones en distintos períodos.
- En particular, se estudian las **distribuciones conjuntas**:

$$f(Y_t, Y_{t-1})$$

- o, de forma equivalente, las **distribuciones condicionales**:

$$f(Y_t \mid Y_{t-1})$$

- La **independencia temporal** implica que el pasado no contiene información relevante sobre el presente, lo que se expresa como:

$$f(Y_t \mid Y_{t-1}) = f(Y_t)$$

- Cuando esta igualdad no se cumple, la serie presenta **dependencia temporal**, y el pasado resulta informativo para la predicción.

Distribución multivariada: ¿una o varias variables?

- El término **distribución multivariada** se refiere a la descripción conjunta de **varios valores aleatorios**, sin importar si provienen de **distintas variables** o de **una misma variable en distintos tiempos**.

1. Análisis multivariado clásico:

- Se estudian varias variables **diferentes** en un mismo tiempo.
- Ejemplo: ingreso, consumo, inversión en $t = 2020$.
- Se usa una distribución multivariada (como la normal multivariada) para modelar su correlación contemporánea.

2. Procesos estocásticos univariados:

- Se analiza **una sola variable** observada en distintos momentos.
- Ejemplo: (Y_t, Y_{t-1}, Y_{t-2}).
- Aunque sea una sola variable, este vector tiene una **distribución multivariada** porque hay dependencia entre valores en el tiempo.

Momentos de vectores aleatorios

- Los **momentos** de un proceso estocástico, al igual que en el caso de una variable aleatoria unidimensional X, se definen como expresiones que resumen características fundamentales del PGD, pueden ser **estimados empíricamente** a partir de una trayectoria observada mediante sus **momentos muestrales**.
- la **tendencia central** (media), la **dispersión** (varianza), y la **dependencia temporal** entre observaciones (autocovarianza y autocorrelación).

$$\mathbb{E}[X_t] = \mu_t < \infty \quad \text{para } t = 1, 2, 3, \ldots, T$$

$$\mathbb{V}[X_t] = \mathbb{E}[(X_t - \mu_x)^2] = \sigma_t^2 = \gamma_0 < \infty \quad \text{para } t = 1, 2, 3, \ldots, T$$

$$\text{Cov}[X_t, X_s] = \mathbb{E}[(X_t - \mu_x)(X_s - \mu_x)] = \gamma_k$$

$$\rho_k = \text{Cor}[X_t, X_s] = \frac{\hat{\gamma}_k}{\hat{\gamma}_0}$$

Función de autocorrelación

- La autocorrelación (**medida empírica de dependencia**) mide asociación lineal entre valores en distintos períodos (autocorrelación poblacional):

$$\rho(k) = Corr(Y_t, Y_{t-k})$$

- Se estudia con las **funciones de autocorrelación** (ACF), que miden la dependencia lineal entre valores de la serie separados k periodos. El **coeficiente de autocorrelación muestral de orden** k se define como:

$$r_k = \frac{\sum_{t=1}^{T-k} (y_t - \bar{y})(y_{t+k} - \bar{y})}{\sum_{t=1}^{T} (y_t - \bar{y})^2} = \frac{\hat{\gamma}_k}{\hat{\gamma}_0}.$$

$$r_k \sim \mathcal{N}\left(0, \frac{1}{T}\right).$$

Funciones de autocorrelación

- Las **funciones de autocorrelación** se representan gráficamente mediante **correlogramas**, donde cada barra indica la autocorrelación muestral $\hat{\rho}_h$ para un desfase h. Las líneas discontinuas alrededor del eje cero representan los **intervalos de confianza** al 95 %, y permiten contrastar la hipótesis nula:

$$H_0 : \hat{\rho}_h = 0 \quad \forall\, h > 0$$

- Bajo la hipótesis de **ruido blanco**, las autocorrelaciones muestrales tienen distribución asintótica:

$$\sqrt{T} \cdot \hat{\rho}_h \xrightarrow{d} \mathcal{N}(0,1) \quad \Rightarrow \quad \hat{\rho}_h \sim \mathcal{N}\left(0, \frac{1}{T}\right)$$

- Si un coeficiente $\hat{\rho}_h$ cae fuera de ese intervalo, se considera **significativamente diferente de cero**, lo que sugiere autocorrelación a ese desfase.

Ejemplo 9: Correlogramas de un ruido blanco

```r
set.seed(3)
n <- 500
w <- ts(rnorm(n,0,1))

acf(w, plot = FALSE)[1:5]
```

```
##
## Autocorrelations of series 'w', by lag
##
##      1      2      3      4      5
## -0.013 -0.025  0.028  0.022 -0.011
```

```r
acf(w, plot = FALSE) %>%
  autoplot(conf.int.fill = '#0000FF') + xlim(1,15)  + ylim(-0.1,0.15) +
  xlab(NULL) + ylab(NULL) + theme(title = element_blank())
```

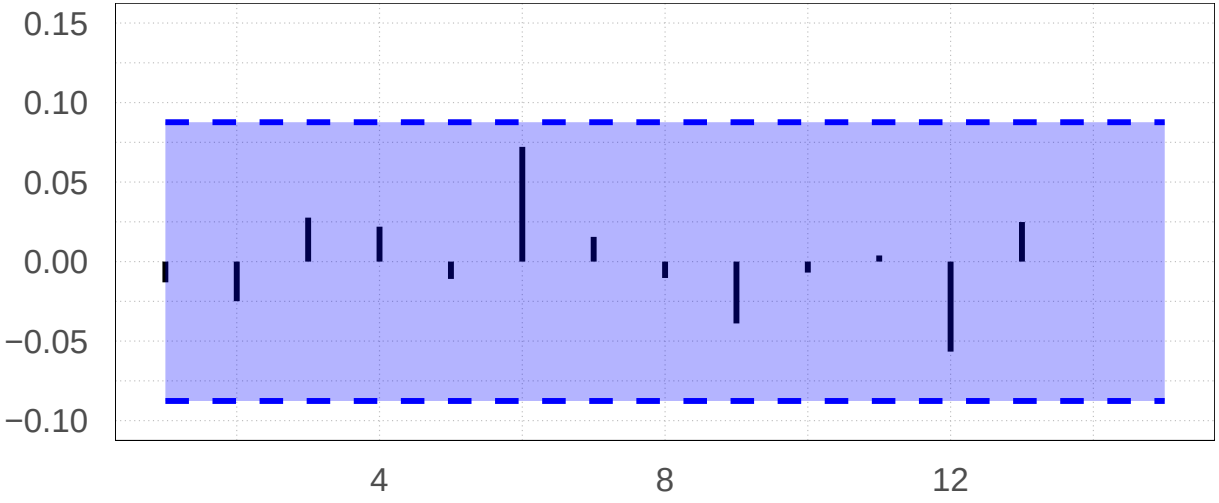

Figura 11: Correlogramas del ruido blanco simulado

Función de autocorrelación parcial

- La **función de autocorrelación parcial (PACF)** mide la correlación entre x_t y x_{t-k} **condicionada** a los valores intermedios $x_{t-1}, \ldots, x_{t-k+1}$. Es decir, elimina el efecto indirecto que los retardos intermedios podrían estar generando sobre la correlación total.

$$a_k = \text{Corr}(x_t, x_{t-k} \mid x_{t-1}, \ldots, x_{t-k+1})$$

- Este coeficiente a_k se obtiene estimando el siguiente modelo autorregresivo mediante Mínimos Cuadrados Ordinarios (MCO):

$$x_t = \beta_0 + \alpha_1 x_{t-1} + \cdots + \alpha_k x_{t-k} + u_t$$

Ejemplo 10: Función de autocorrelación parcial

```r
pacf(w, plot = FALSE)[1:5]
```

```
##
## Partial autocorrelations of series 'w', by lag
##
##      1      2      3      4      5
## -0.013 -0.025  0.027  0.022 -0.009
```

```r
pacf(w, plot = FALSE) %>%
  autoplot(conf.int.fill = '#0000FF') + xlim(1,15)  + ylim(-0.1,0.15) +
  xlab(NULL) + ylab(NULL)  + theme(title = element_blank())
```

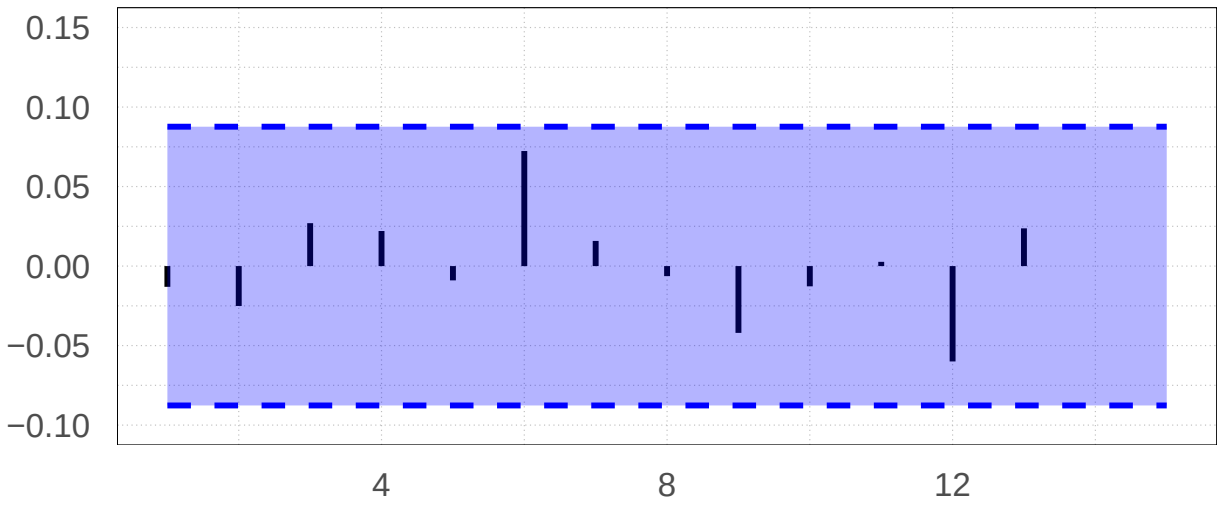

Figura 12: Correlogramas de las series

Test de autocorrelación

- Además del análisis visual mediante **correlogramas**, se dispone de pruebas estadísticas formales como el **test de Box**, que permite contrastar la existencia de autocorrelación en una serie temporal.
- El objetivo es evaluar la hipótesis nula de **ausencia de autocorrelación** hasta un rezago h:

$$H_0 : \rho_k = 0 \quad \forall\, k = 1, \ldots, h \qquad H_A : \exists\, k \leq h \text{ tal que } \rho_k \neq 0$$

- El estadístico propuesto por **Box y Pierce (1970)** es:

$$Q_h = T \sum_{k=1}^{h} \hat{\rho}_k^2 \sim \chi_h^2$$

- Si Q_h excede el valor crítico del χ^2 con h grados de libertad, se **rechaza** H_0 y se concluye que existe **dependencia serial significativa**.

Test de autocorrelación

- Posteriormente, **Ljung y Box (1978)** propusieron una versión mejorada del test de autocorrelación de Box-Pierce, con un ajuste por sesgo en muestras finitas.
- El estadístico de prueba **Ljung-Box** se define como:

$$Q_h = T(T+2)\sum_{k=1}^{h} \frac{\hat{\rho}_k^2}{T-k} \sim \chi_h^2$$

- Donde: T: tamaño de la muestra; $\hat{\rho}_k$: coeficiente de autocorrelación muestral en el rezago k; h: número de rezagos considerados.Permite contrastar:

$$H_0 : \rho_k = 0 \quad \forall\, k = 1, \ldots, h \quad \text{vs.} \quad H_A : \exists\, k \leq h \text{ tal que } \rho_k \neq 0$$

- Si se rechaza H_0, se concluye que la serie presenta **autocorrelación residual**, indicando que puede requerir modelado ARMA.

Ejemplo 11: Test de autocorrelación en R

```r
Box.test(w, lag = 1, type = "Box-Pierce")
```

```
##
##  Box-Pierce test
##
## data:  w
## X-squared = 0.085185, df = 1, p-value = 0.7704
```

```r
Box.test(w, lag = 1, type = "Ljung-Box")
```

```
##
##  Box-Ljung test
##
## data:  w
## X-squared = 0.085697, df = 1, p-value = 0.7697
```

Ruido blanco

- Si la autocorrelación captura dependencia sistemática, el **ruido blanco** representa lo que no se puede explicar ni predecir. El **ruido blanco** es:

$$X_t = \varepsilon_t$$

- Donde ε_t se denomina **innovación** y se asume que es una variable aleatoria **independiente e idénticamente distribuida (i.i.d.)**, con distribución normal. Es decir:
  - $\mathbb{E}[\varepsilon_t] = 0$
  - $\text{Var}(\varepsilon_t) = \sigma^2$
  - $\text{Cov}(\varepsilon_t, \varepsilon_s) = 0 \quad \forall\, t \neq s$
- También puede definirse como un proceso **sin autocorrelación**, de modo que sus valores no son predecibles a partir del pasado. Por ello, se le llama "ruido" en sentido estadístico.
- La **ausencia de autocorrelación serial**, implica **independencia** (o al menos no linealidad) entre observaciones en distintos momento

Caminata aleatoria (Random Walk)

- Un ejemplo clásico de serie temporal con dependencia es la **caminata aleatoria**, cuya **primera diferencia** sigue un ruido blanco: $\Delta x_t = x_t - x_{t-1} = \epsilon_t$.

$$x_t = x_{t-1} + \epsilon_t, \quad t = 1, 2, \ldots, T; \quad \epsilon_t \sim RB(0, \sigma_\epsilon^2)$$

- En este caso, la serie no presenta reversión a la media ni varianza constante, propiedades esenciales para la estacionariedad.
- De forma más general, la caminata aleatoria puede incluir una **deriva determinística**:

$$x_t = \alpha_0 t + x_{t-1} + \epsilon_t$$

- Aquí, el término $\alpha_0 t$ introduce una **tendencia lineal**, reforzando la no estacionariedad de la serie.

Caminata aleatoria

- La **caminata aleatoria** puede interpretarse como una **acumulación sucesiva de choques aleatorios** (innovaciones), donde cada valor depende del anterior más un nuevo shock:

$$x_t = x_{t-1} + u_t, \quad u_t \sim RB(0, \sigma^2)$$

- Al sustituir recursivamente:

$$x_{t-1} = x_{t-2} + u_{t-1} \quad \Rightarrow \quad x_t = x_{t-2} + u_{t-1} + u_t$$

- Iterando hacia atrás, el valor actual de la serie es la **suma acumulada de los choques pasados**.:

$$x_t = x_0 + \sum_{j=1}^{t} u_j$$

Ejemplo 12: Caminata aleatoria y persistencia de x_t

- Esta representación refleja claramente la **no estacionariedad** del proceso:
  - La **varianza de** x_t crece con el tiempo ($\text{Var}(x_t) = t\sigma^2$).
  - No hay reversión a la media.
  - Cada nueva innovación genera un efecto **permanente** sobre la serie.

```
rw <- ts(cumsum(w))
```

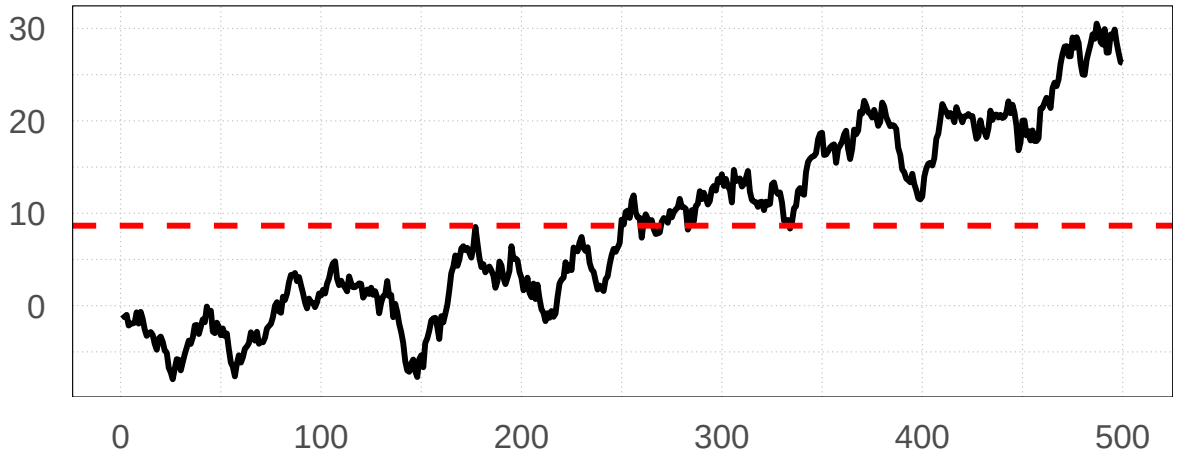

Figura 13: Simulando una caminata aleatoria

Caminata aleatoria con deriva (with Drift)

- La **caminata aleatoria con deriva** extiende la caminata aleatoria básica incorporando una tendencia determinística lineal. Se define como:

$$x_t = \alpha_0 + x_{t-1} + \epsilon_t, \quad t = 1, 2, \ldots, T$$

- Donde:
  - α_0 es el término de **deriva** o tendencia constante.
  - $\epsilon_t \sim RB(0, \sigma^2)$ es un ruido blanco.
- Esta definición implica que cada paso de la serie suma:
  - El valor anterior x_{t-1},
  - Una constante α_0 que introduce una pendiente,
  - Un shock aleatorio ϵ_t.
- Por tanto, la serie tiende a **incrementarse o decrecer sistemáticamente** en el tiempo, además de la variabilidad aleatoria. Esto refuerza la **no estacionariedad** del proceso, dado que la media cambia en t:

$$\mathbb{E}[x_t] = x_0 + \alpha_0 t$$

Ejemplo 13: Correlograma de una caminata aleatoria

- Note como los coeficientes de autocorrelación pasan a ser significativos inclusive dentro de un alto orden de retardos.

```
##
## Autocorrelations of series 'rw', by lag
##
##     1     2     3     4     5
## 0.990 0.981 0.971 0.960 0.949
```

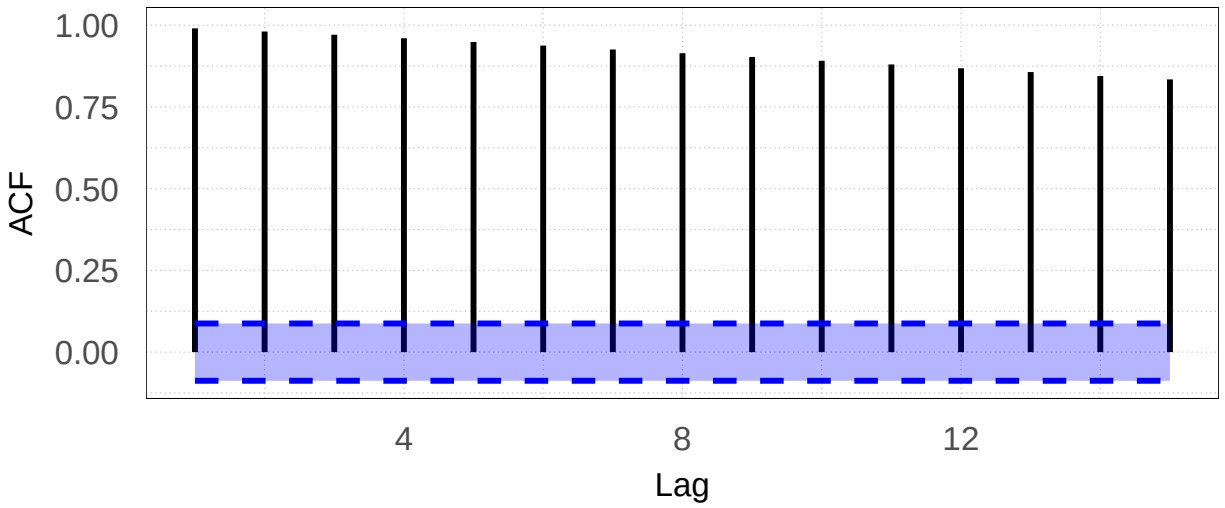

Figura 14: Correlogramas de la caminata aleatoria simulada

Section 5

Modelar dependencia temporal

¿Por qué modelar dependencia temporal?

- Sea $\{y_t\}$ un proceso estocástico adaptado a la filtración $\mathcal{F}_{t-1}$.
- Decimos que existe dependencia temporal si:

$$E(y_t \mid \mathcal{F}_{t-1}) \neq E(y_t)$$

- Equivalente a:

$$Cov(y_t, y_{t-k}) \neq 0 \quad \text{para algún } k > 0$$

Modelo AR(1)

Pasar de medición a modelización

- Una forma paramétrica de **modelar dependencia temporal** es:

$$Y_t = \mu + \rho(Y_{t-1} - \mu) + \varepsilon_t, \quad \varepsilon_t \sim iid(0, \sigma^2)$$

- ρ mide persistencia
- La media condicional depende del pasado
- La memoria es finita si $|\rho| < 1$ (ver anexo 2)

- El AR(1) aparece como una hipótesis paramétrica sobre:

$$f(y_t|y_{t-1})$$

Proceso autoregresivo

- Al asumir este modelo consideramos que la **caminata aleatoria** es un caso especial de una serie autoregresiva ($\phi = 1$):

$$y_t = \alpha + \phi y_{t-1} + \epsilon_t$$

- Donde $\phi = 1$ recoge la persistencia de la serie.

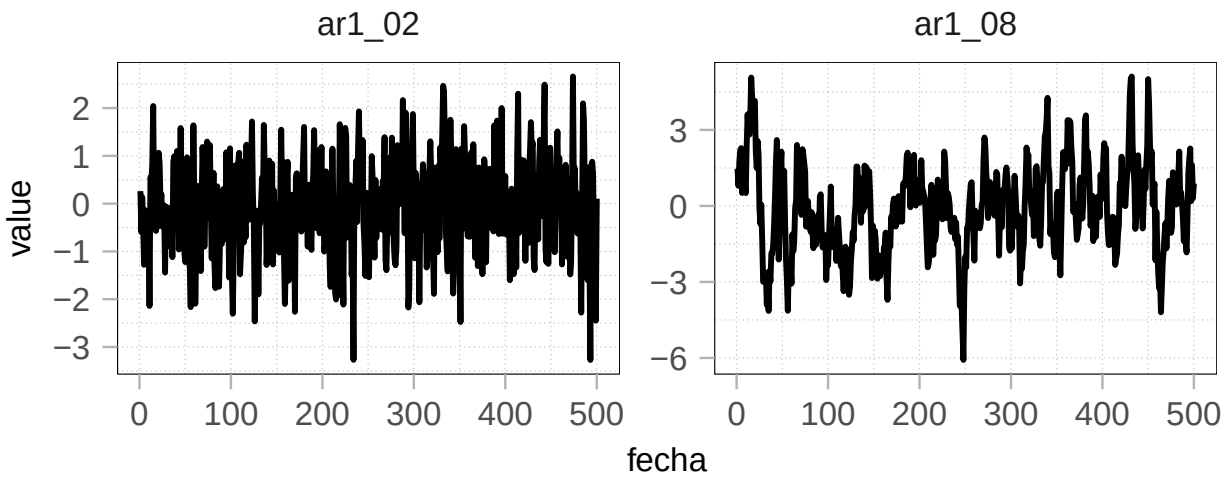

Figura 15: Proceso autoregresivo

Autocorrelación como evidencia empírica

- La autocorrelación muestral permite detectar dependencia temporal:

$$\widehat{\rho}(k) = Corr(\pi_t, \pi_{t-k})$$

- No es el proceso
- No es el DGP
- Es una **huella observable** de dependencia

A partir de ella proponemos modelos, por ejemplo: AR(1) para inflación que es una hipótesis probabilística común es:

$$\Pi_t = \mu + \rho(\Pi_{t-1} - \mu) + \varepsilon_t$$

con:

$$\varepsilon_t \sim iid(0, \sigma^2)$$

- Este modelo especifica explícitamente la **distribución condicional** de la inflación.
- A partir de una sola trayectoria: estimamos μ, ρ, σ^2, evaluamos compatibilidad del modelo con los datos e inferimos propiedades del proceso.

AR(1)

- Una serie temporal $\{Y_t\}$ que sigue un proceso autorregresivo de orden 1 (AR(1)) está definida por:

$$Y_t = \phi Y_{t-1} + \varepsilon_t$$

- Donde:
  - ϕ es el coeficiente autorregresivo.
  - ε_t es ruido blanco con esperanza cero y varianza constante:

$$\mathbb{E}[\varepsilon_t] = 0, \quad \text{Var}[\varepsilon_t] = \sigma^2.$$

- Reescribiendo la ecuación en diferencias, obtenemos:

$$\Delta Y_t = Y_t - Y_{t-1} = (\phi - 1) Y_{t-1} + \varepsilon_t$$

Persistencia

- El parámetro autorregresivo ϕ determina la **dinámica y estabilidad** de la serie temporal $\{Y_t\}$:
  - Cuando $|\phi| < 1$, el impacto de un choque ε_t en el valor presente se **disipa gradualmente** a medida que pasa el tiempo.
    La serie tiende a **revertir a su media**, exhibiendo memoria corta y una dinámica estable.
    La influencia del valor inicial Y_0 se desvanece conforme $t \to \infty$.
  - Si $\phi = 1$, la serie se comporta como una **caminata aleatoria** (random walk).
    En este caso, los choques se acumulan sin amortiguación, y la serie no muestra reversión a la media ni estacionariedad.
    El valor presente depende fuertemente de la suma de choques pasados, lo que genera alta volatilidad.
  - Cuando $\phi > 1$, el proceso es **explosivo**: los choques y el valor inicial se amplifican exponencialmente con el tiempo, provocando valores cada vez mayores y una dinámica inestable.

Ejemplo 14: *Series temporales y modelos*

- En síntesis, ϕ controla la **persistencia** de los choques y la **velocidad de ajuste** de la serie hacia su media o hacia valores extremos.

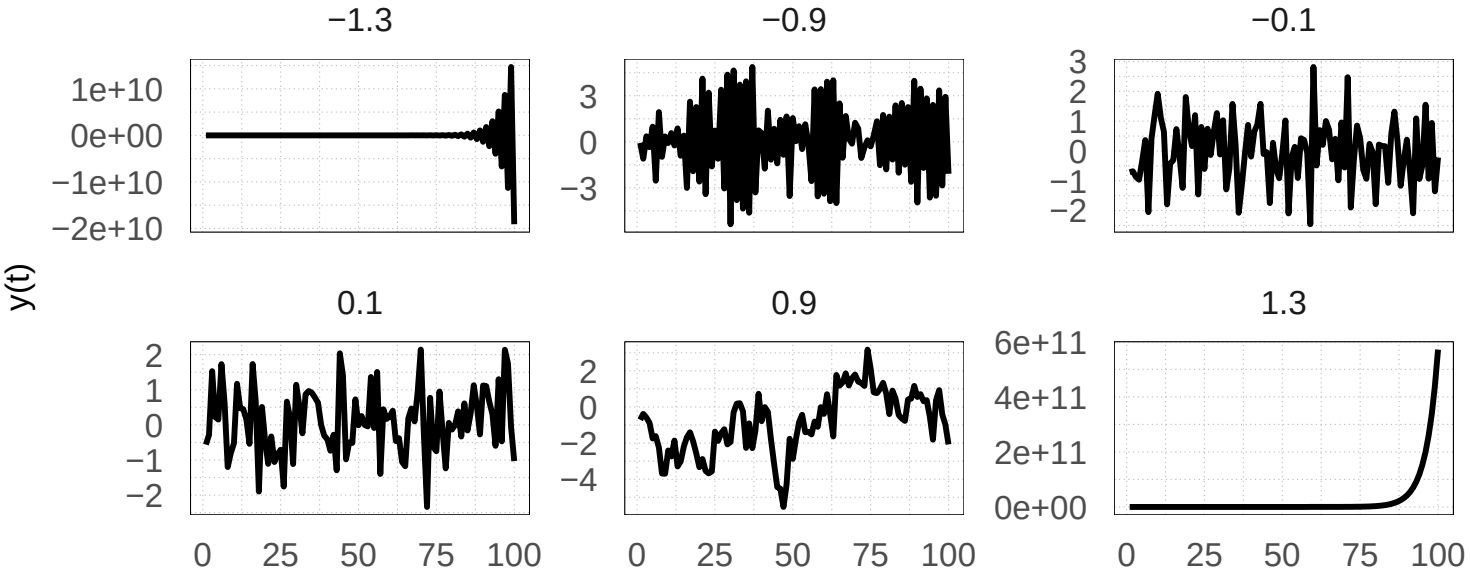

Figura 16: Sismulación de series AR(1) con diferentes coeficientes autoregresivos

Lección central de la clase

En macroeconometría:

- observamos una **serie temporal**, es decir,una realización particular de un proceso estocástico no observado;
- analizamos sus **propiedades dinámicas**, en particular la presencia de dependencia temporal;
- caracterizamos empíricamente dicha dependencia (por ejemplo, mediante la autocorrelación);
- y, en función de este diagnóstico, **proponemos un modelo probabilístico adecuado** para el proceso generador de datos.

Dependencia temporal y modelización

- Cada técnica empírica responde a una pregunta distinta sobre el proceso inflacionario, no a una necesidad técnica arbitraria.
- **Si no hay autocorrelación:**
  - La serie puede modelarse como ruido blanco.
  - El análisis inferencial tradicional es válido.
- **Si hay autocorrelación:**
  - Existe persistencia temporal.
  - Es necesario proponer un modelo dinámico:
    - AR(1), ARMA, u otra especificación adecuada.
- En este punto, el modelo representa una hipótesis explícita sobre la distribución condicional del proceso.

Section 6

Referencias

Referencias I

- Alonso, A. (*nd*). Introducción al Análisis de Series Temporales. UC3M.
- Alonso, A. (nd). Time series and stochastic processes. UC3M.
- Adhikari, R. & Agrawal, R. An Introductory Study on Time Series Modeling and Forecasting.
- Box, G.; Jenkins, G., (1976), Time Series Analysis: Forecasting and Control. San Francisco: Holden-Day.
- Box, G.; Pierce, D. (1970), Distribution of residual correlations in autoregressive-integrated moving average time series models. Journal of the American Statistical Association, 65, 1509–1526.
- Boateng, N. (2018). Time Series Forecasting.
- Brockwell, P. and Davis, R. (2002). Introduction to Time Series and Forecasting. Second Edition. Springer.
- Coghlan, A. (2016). A Little Book of R For Time Series.
- Cowpertwait, P.; Metcalfe, A., (2009). Introductory Time Series with R. Springer.
- Cryer, J., Chan, K., (2008). Time Series Analysis. With Applications in R. Second Edition. Springer.
- Madsen, H. Time Series Analysis Technical University of Denmark.
- Favero, C. A. (2001). Applied Macroeconometrics.
- Gentleman, R.; Hornik, K. amd Parmigiani, G. (2011). Introductory Time Series with R.
- Guerrier, S.; Molinari, R.; Xu, H.; Zhang, Y. (2019). Applied Time Series Analysis with R.
- Holmes, E.; Scheuerell, D.; Ward, E. (2021). Applied Time Series Analysis for Fisheries and Environmental Sciences. Universidad Complutense de Madrid.
- Mills, T., (2019). Applied Time Series Analysis. A Practical Guide to Modeling and Forecasting. Loughborough University, Loughborough, United Kingdom.
- Soto, Raimundo (2010). Econometría de series temporales. Pontificia Universidad de Chile.

Referencias II

- Shumway, R.; Stoffer, D., (2011). Analysis and Its Applications: With R Examples Its Applications. Third Edition. Springer.
- Tsay, R. Analysis of Financial Time Series. Second edition. University of Chicago. Graduate School of Business.
- Wei, W., (1989). Time series Analysis. Univariate and multivariate methods. Pearson.
- Willems, K. (2017). xts Cheat Sheet: Time Series in R.
- Wurtz, D. and, Tobias (2014). Plotting 'timeSeries' Objects.
- Yutani, H. (2022). Introduction to gghighlight.
- Zucchini, W.; Nenadie, O. (s.f.d.). Time Series Analysis with R. Part I.

Section 7

Anexos

Subsection 1

Comunicación de datos con ggplot

Ejemplo 15: Comunicación de datos con ggplot2, un sistema de gráficos basado en **la gramática de los datos**.

```
library(tidyverse)

datos <- as.data.frame(EuStockMarkets)
datos$fecha <- time(EuStockMarkets)  # convierte el índice de tiempo a fechas

ggplot(datos, aes(x = fecha)) +
  geom_line(aes(y = DAX)) +
  geom_line(aes(y = FTSE), color="blue")
```

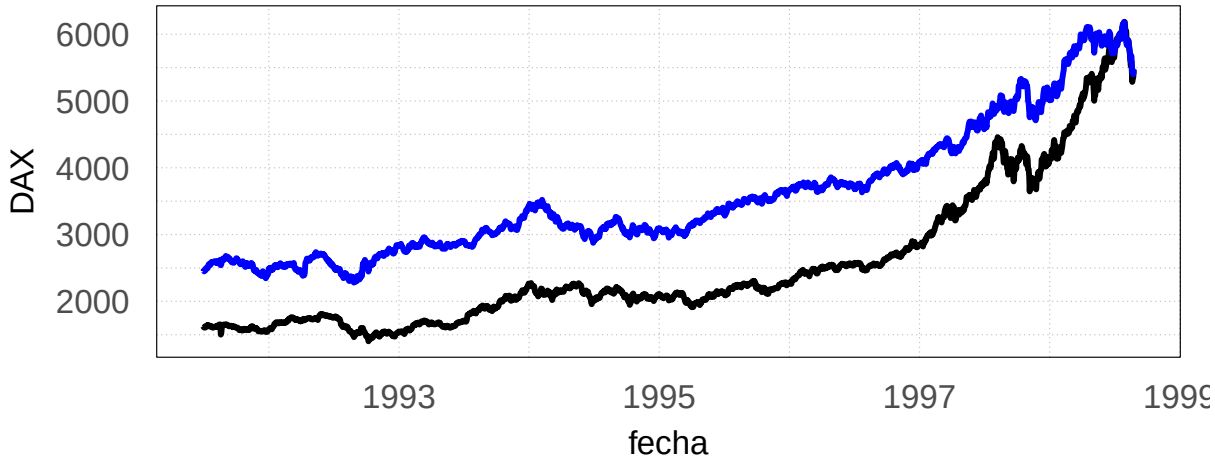

Figura 17: Índices bursátiles europeos (EuStockMarkets). Datos diarios 1991-1998

Ejemplo 15: Formato wide vs. long

```r
library(RColorBrewer)  # para paletas de colores

# Convertir a formato largo (long format)
datos_long <- datos %>%
  pivot_longer(cols = -fecha, names_to = "indice", values_to = "valor")

ggplot(datos_long, aes(x = fecha, y = valor, color = indice)) +
  geom_line(size = 0.8) +
    labs(x =  element_blank(),  y = "Índice", color = "Mercados") +
  scale_color_brewer(palette = "Set1")
```

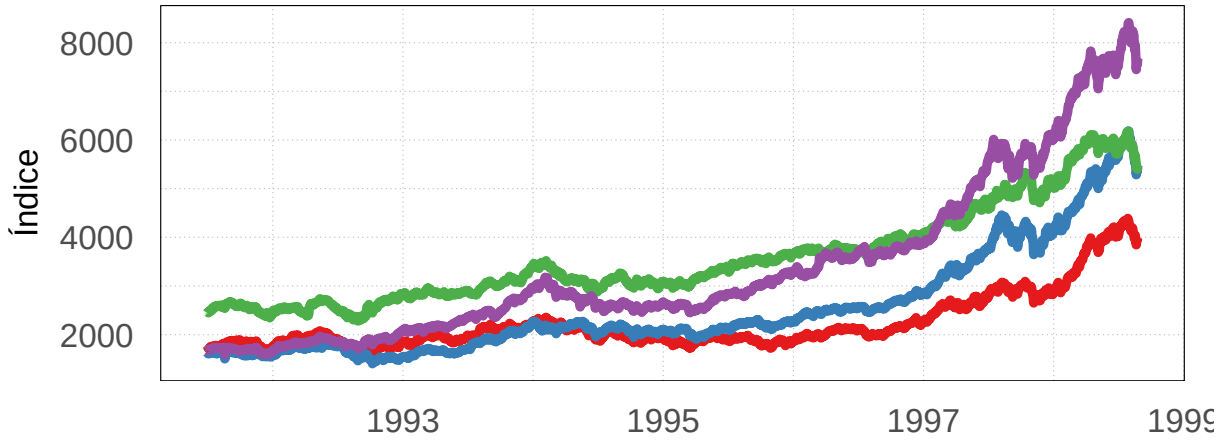

Figura 18: Índices bursátiles europeos (EuStockMarkets). Datos diarios 1991-1998

Ejemplo 15: Panel gráfico

```
ggplot(datos_long, aes(x = fecha, y = valor, color = indice)) +
  geom_line(size = 0.8) +
  facet_wrap(~ indice) +
  labs(x =  element_blank(),  y = "Índice", color = "Mercados")
```

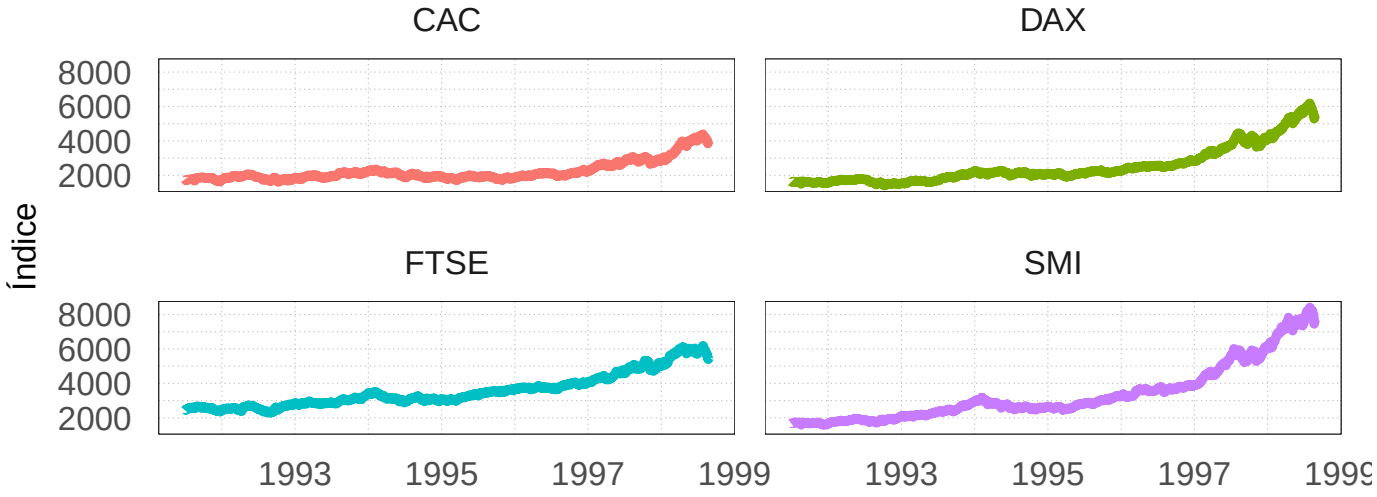

Figura 19: Índices bursátiles europeos (EuStockMarkets). Datos diarios 1991-1998

Ejemplo 15: Gghighlight + combinación

```
library(gghighlight)
library(patchwork)
p1 <- ggplot(datos_long, aes(x = fecha, y = valor, color = indice)) +
  geom_line(size = 0.8) + labs(x =  element_blank()) +
  gghighlight(max(valor) > 7000)

p2 <- ggplot(datos_long, aes(x = fecha, y = valor, color = indice)) +
  geom_line(size = 0.8)  + labs(x =  element_blank(), y=element_blank()) +
  gghighlight(indice == "DAX")

p1 | p2
```

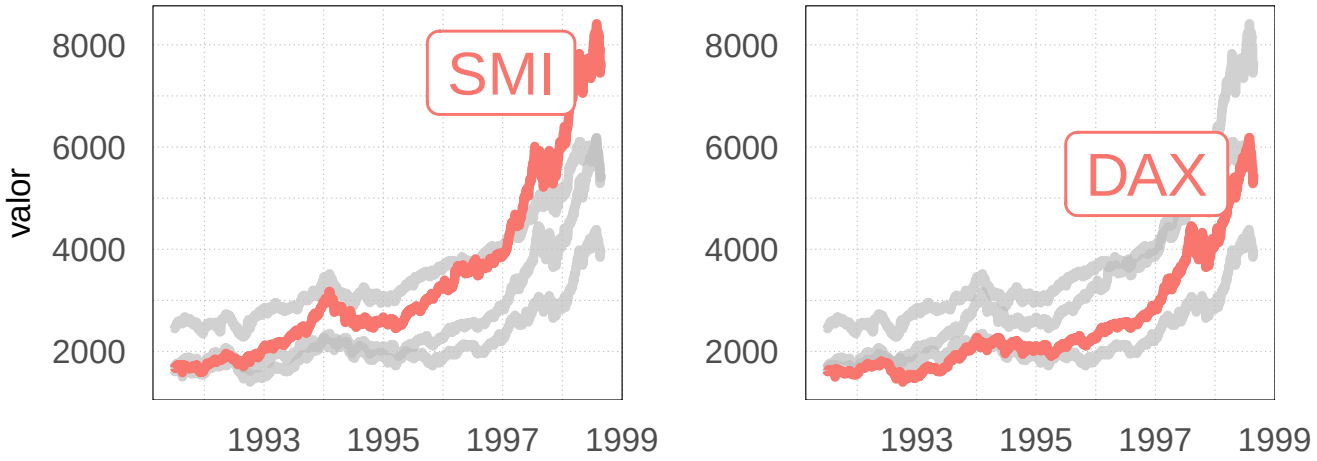

Figura 20: Índices bursátiles europeos (EuStockMarkets). Datos diarios 1991-1998

Ejemplo 15: Etiquetas de variables (**labeller**)

```
variable_labels <- c(
  DAX = "Alemania (DAX)",
  SMI = "Suiza (SMI)",
  CAC = "Francia (CAC 40)",
  FTSE = "Reino Unido (FTSE 100)"
)

datos_long |>
  group_by(indice) |>
  slice_tail(n = 300) |>
  ggplot(aes(x = fecha, y = valor)) + labs(x =  element_blank()) +
  geom_line(aes(color = indice), size = 0.8) +
  facet_wrap(~indice, scales = "free_y", ncol = 2, labeller = labeller(indice = variable_labels)
```

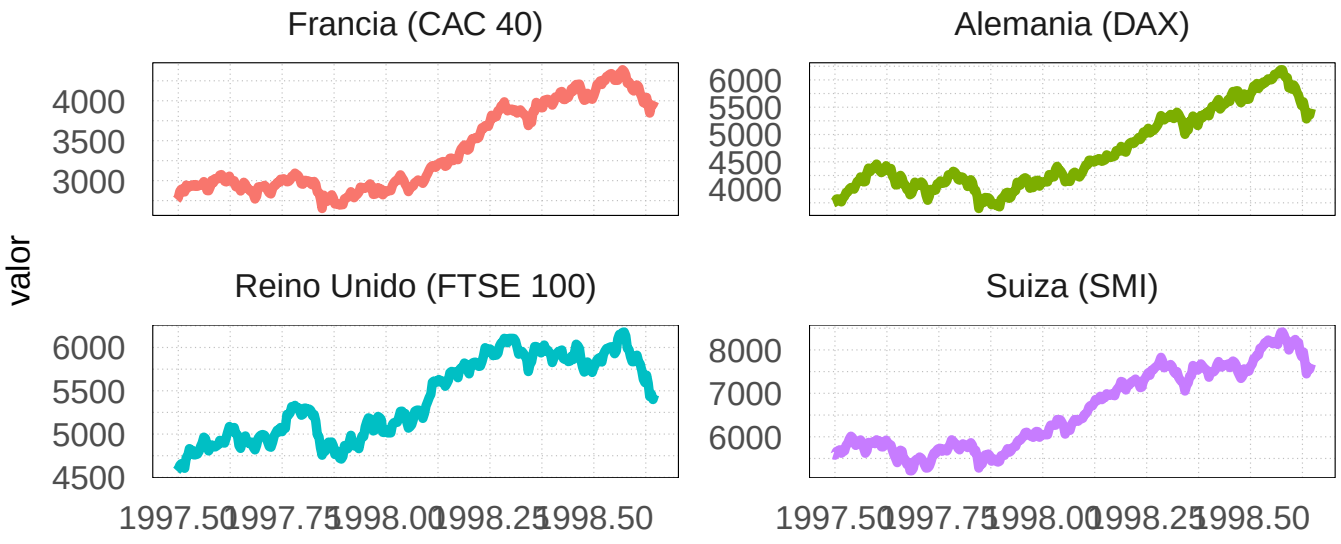

Figura 21: Índices bursátiles europeos (EuStockMarkets). Datos diarios 1991-1998

Subsection 2

Ecuación en diferencias: AR(1)

Expansión recursiva

- Partimos del modelo autorregresivo de orden 1 (AR(1)):

$$Y_t = \phi Y_{t-1} + \varepsilon_t$$

- Iterando recursivamente:
  - Para $t = 1$: $Y_1 = \phi Y_0 + \varepsilon_1$
  - Para $t = 2$: $Y_2 = \phi^2 Y_0 + \phi\varepsilon_1 + \varepsilon_2$
  - Para $t = 3$: $Y_3 = \phi^3 Y_0 + \phi^2\varepsilon_1 + \phi\varepsilon_2 + \varepsilon_3$
- Generalizando:

$$Y_t = \phi^t Y_0 + \sum_{j=0}^{t-1} \phi^j \varepsilon_{t-j}$$

- La dinámica del proceso depende directamente del valor del parámetro ϕ y del valor inicial Y_0.
  - $\phi^t Y_0$ representa la influencia del valor inicial.
  - $\sum_{j=0}^{t-1} \phi^j \varepsilon_{t-j}$ acumula los shocks pasados, amortiguados por el factor ϕ^j.

Dinámica

- $|\phi| < 1$: estacionaria y ergódica. Converge hacia la media.

$$Y_t = \phi^t Y_0 + \sum_{j=0}^{t-1} \phi^j \varepsilon_{t-j}$$

  $\Rightarrow \phi^t \to 0$ cuando $t \to \infty$.
- $\phi = 1$: Random Walk (caminata aleatoria).

$$Y_t = Y_0 + \sum_{j=1}^{t} \varepsilon_j$$

  $\Rightarrow$ no hay reversión a la media, **ni estacionariedad**.
- $\phi > 1$: **proceso explosivo**. El valor de la serie se amplifica con el tiempo.